# Análise de séries temporais

por similaridade e alinhamento não linear com Dynamic Time Warping





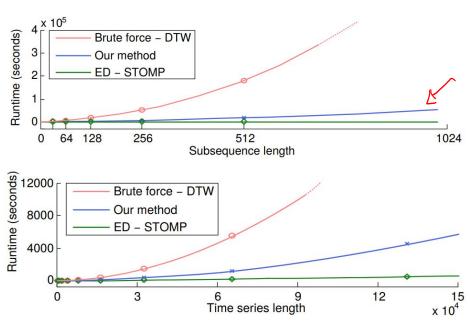




#### MP com DTW

$$O(ln^2)$$
 $problems$ 
 $O(l^2n^2) \Rightarrow l costums ser$ 
 $JCR-USP Suite (com PSI)$ 

A primeira tentativa foi adaptar o UCR-USP Suite (com PSI)



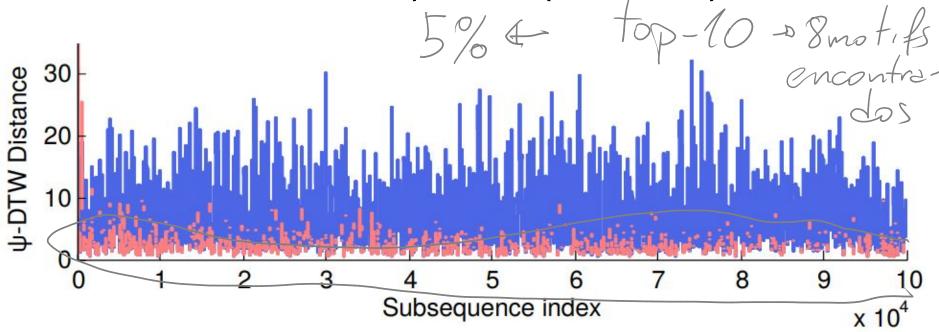
Silva, D. F., & Batista, G. E. (2018, December). Elastic time series motifs and discords. In 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA) (pp. 237-242). IEEE.

#### MP com DTW

Mais lento, mas muito mais significativo

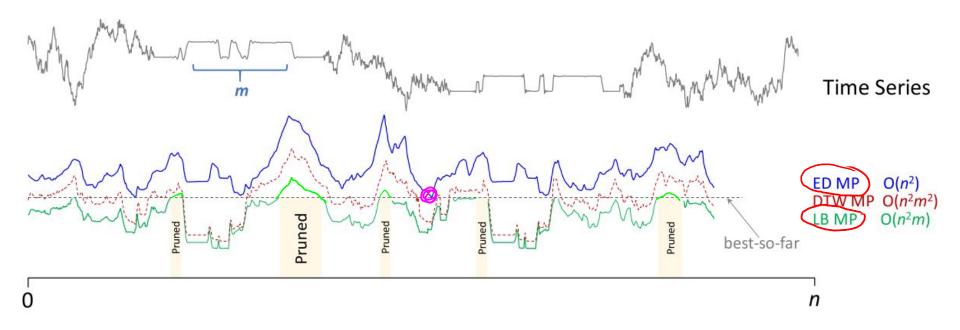
- Tende a achar padrões menos "flat"
- Não assume como discord uma subsequência com vizinho próximo, mas com pequeno warping
- Não descarta motif por conta de prefixos e sufixos

MP com DTW - mais eficiente para motifs



Silva, D. F., & Batista, G. E. (2018, December). Elastic time series motifs and discords. In 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA) (pp. 237-242). IEEE.

# MP com DTW - mais eficiente para motifs



# Outras variações

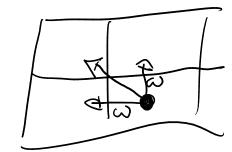
## Weighted Slope DTW

Adicionamos um peso aos passos "não-diagonais"

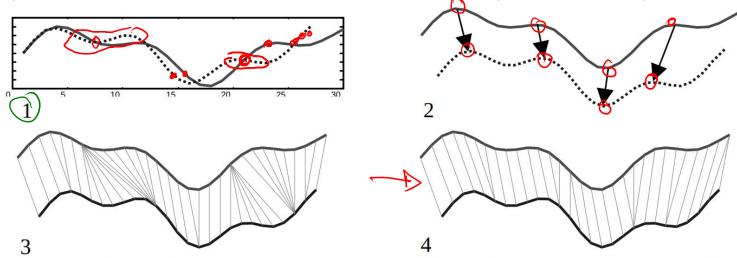
$$dtw(i,j) = c(x_i,y_j) + min \begin{cases} dtw(i-1,j) \cdot \mathbf{w} \\ dtw(i,j-1) \cdot \mathbf{w} \\ dtw(i-1,j-1) \end{cases}$$

Também é possível fazer outros tipos de ponderação





A princípio, DTW deveria "casar formatos". Mas, na prática, casa pontos.



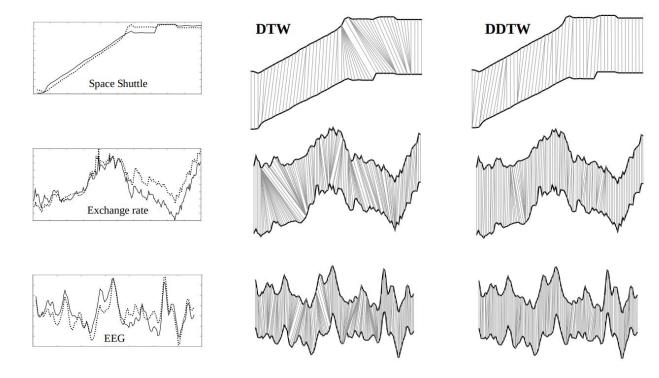
**Figure 6: 1)** Two artificial signals. **2)** The intuitive feature to feature warping alignment. **3)** The alignment produced by classic DTW. **4)** The alignment produced by DDTW.

Keogh, E. J., & Pazzani, M. J. (2001, April). Derivative dynamic time warping. In Proceedings of the 2001 SIAM international conference on data mining (pp. 1-11). Society for Industrial and Applied Mathematics.

A DDTW apenas estima a derivativa antes de fazer o alinhamento:

$$D_x[q] = rac{(q_i - q_{i-1}) + (q_{i+1} - (q_{i-1}))/2}{2}$$

+ exemplos



Keogh, E. J., & Pazzani, M. J. (2001, April). Derivative dynamic time warping. In Proceedings of the 2001 SIAM international conference on data mining (pp. 1-11). Society for Industrial and Applied Mathematics.

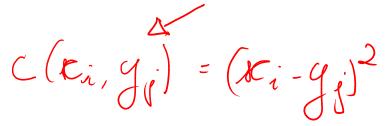


# Metric learning

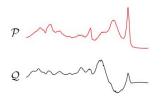
Mas o que exatamente são "shapes" que deveriam casar?

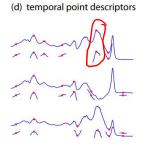
- Talvez dependa do domínio.
- Podemos aprender com os próprios dados, então?
- Alguns trabalhos propõem aprender uma medida para substituir a euclidiana como custo

#### Metric DTW

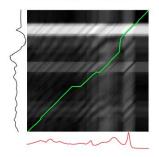


(a) input sequences

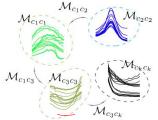




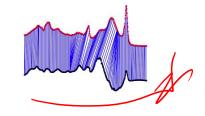
(b) DTW alignment path P



(e) descriptors clusters



(c) DTW alignment



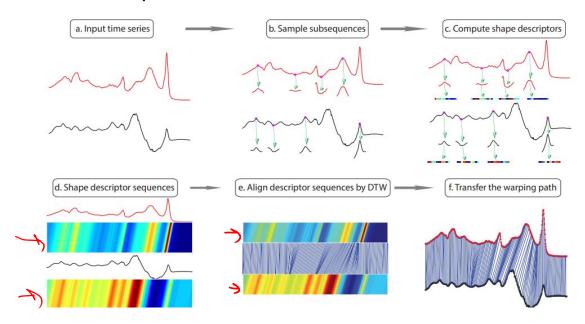
(f) DTW distance under learned metrics

$$D(\mathcal{P}, \mathcal{Q}) = \sum_{(i,j) \in \mathbf{p}} (\overrightarrow{p_i} - \overrightarrow{q_j})^T \mathcal{M}_{c_i c_j} (\overrightarrow{p_i} - \overrightarrow{q_j})$$

$$\mathcal{M}_{c_k c_k}$$

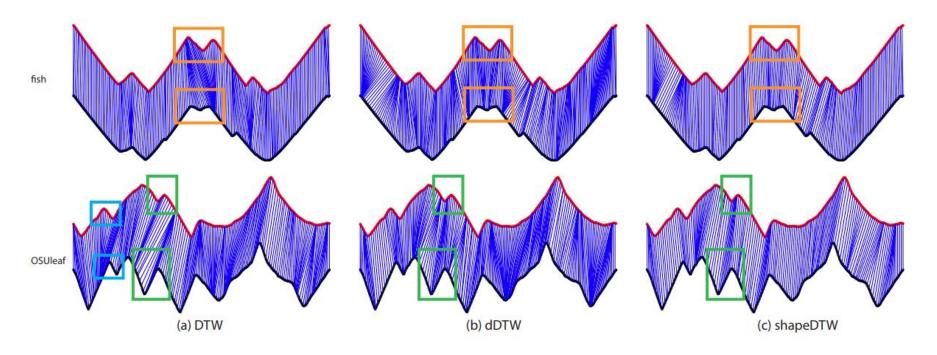
### ShapeDTW

Extrai descritores de shape e os alinha com DTW



Zhao, J., & Itti, L. (2018). shapeDTW: Shape dynamic time warping. Pattern Recognition, 74, 171-184.

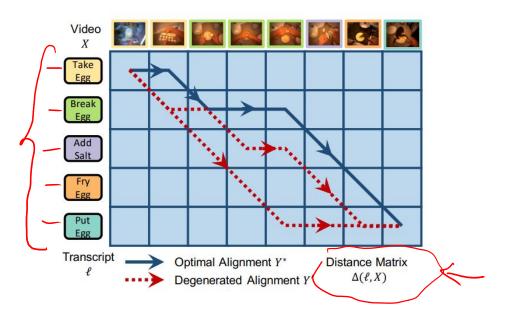
# ShapeDTW



Zhao, J., & Itti, L. (2018). shapeDTW: Shape dynamic time warping. Pattern Recognition, 74, 171-184.

#### D3TW

um exemplo de matriz de custo que não tem nada a ver com distância



Chang, C. Y., Huang, D. A., Sui, Y., Fei-Fei, L., & Niebles, J. C. (2019). D3tw: Discriminative differentiable dynamic time warping for weakly supervised action alignment and segmentation. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (pp. 3546-3555).

Para não dizer que não fizemos nada aqui, façam um exercício

- Utilizem o notebook de alinhamento que vocês fizeram
- Criem um método para calcular a derivativa (DDTW)
- Alinhem as séries
- Plotem o resultado e comparem com a DTW padrão

$$D_x[q] = rac{(q_i - q_{i-1}) + (q_{i+1} - (q_{i-1}))/2}{2}$$